



SAMSUN ÜNİVERSİTESİ

Mühendislik ve Doğa Bilimleri Fakültesi

Yazılım Mühendisliği Bölümü

BİTİRME PROJESİ ARA RAPORU

Ders Kodu

MYAZ404

Öğrenci Numarası

221118024

Öğrencinin Adı - Soyadı

Emin ALTAN

Danışman

Dr.Öğretim Üyesi Nurettin Şenyer

Proje Adı

Dağıtık Yapay Zeka Ajanları İçin
Maliyet-Etkin MapReduce Orkestrasyon
Altyapısı: Tıp Dikeyinde Otonom Nitel Veri
Analizi (context-qualitative)

Teslim Dönemi

2025-2026 Bahar Dönemi

1. Özet

Özet Metni

Bu çalışma kapsamında, tıp dikeyinde yürütülen nitel araştırmaların (derinlemesine mülakatlar, odak grup görüşmeleri ve açık uçlu klinik anketler) analiz süreçlerini otonomize eden, maliyet-etkin ve dağıtık bir yapay zeka ajan orkestrasyon altyapısı geliştirilmektedir. Mevcut nitel analiz süreçleri, MAXQDA ve NVivo gibi yüksek lisans maliyetli yazılımlara bağımlı olup, araştırmacıların verileri manuel kodlaması aylar süren bir iş yükü yaratmaktadır. Öte yandan, hassas klinik verilerin doğrudan genel bulut tabanlı Büyük Dil Modellerine (LLM) yüklenmesi, hem KVKK/HIPAA veri gizliliği protokollerini ihlal etmekte hem de modellerin "bağlam penceresi" (context window) kısıtları nedeniyle bilgi kaybına yol açmaktadır.

Geliştirilen "context-qualitative" (Med-AgentLab) sistemi, bu sorunları "MapReduce" mimarisiyle çözmeyi amaçlamaktadır. Sistem; ham veriyi anlam bütünlüğünü koruyacak şekilde parçalara bölen bir Chunker, veriyi internete çıkmadan yerel donanımda anonimleştiren bir Gizlilik Bekçisi (Ollama), tematik kodları çıkaran Mapper filosu ve çıktıları literatürle doğrulayan bir Validator katmanından oluşmaktadır. Ara rapor dönemine kadar, sistemin tüm girdi-çıkış kontratlarını içeren teknik şartnamesi hazırlanmış, çoklu ajan orkestrasyonu için gerekli olan LiteLLM ve asenkron yapılandırma tasarlanmıştır. Ayrıca, kullanıcı deneyimini optimize etmek adına Streamlit tabanlı arayüz taslakları oluşturulmuştur.

2. Proje Amacı ve Hedefi

Amaç ve Hedef Açıklaması

Projenin ana amacı, tıbbi nitel araştırmalardaki veri işleme süresini ve maliyetini minimize ederken, akademik geçerliliği yüksek, denetlenebilir ve gizlilik odaklı bir otonom analiz framework'ü sunmaktır. Bu genel amaca ulaşmak için şu teknik hedefler belirlenmiştir:

- Mimarinin Kurulması:** 4GB VRAM gibi kısıtlı donanımlarda bile çalışabilen, yerel ve bulut tabanlı modelleri hibrit bir yapıda yöneten bir orkestrasyon altyapısı inşa etmek.
- Veri Gizliliğinin Ölçülebilirliği:** Yerel Ollama ajanının Türkçe tıbbi metinlerdeki kişisel verileri (PII) tespit etme başarısını **Recall ≥ 0.95** ve **Precision ≥ 0.90** düzeyine ulaştırmak.
- Akademik Geçerlilik:** Sistem tarafından üretilen tematik kodların, uzman bir araştırmacı tarafından yapılan manuel kodlamalarla olan örtüşme oranını (F1-Skoru) **0.80 ve üzeri** seviyesine taşımak.

- **Halüsinasyon Denetimi:** Medikal Teyit Ajanı (Validator) aracılığıyla, literatürde karşılığı olmayan tıbbi çıkarımların raporlara sızmasını engelleyen bir denetim mekanizması (ratchet) kurmak.

3. Giriş

Problem Tanımı (Konunun Kapsamı ve Önemi) ve Literatür Taraması

Günümüzde tıbbi araştırmalarda nitel veri analizi, lisans ücretleri yüksek olan geleneksel yazılımlar kullanılarak manuel olarak yapılmaktadır. Bu durum, araştırmacılar için ciddi bir zaman ve maliyet darboğazı yaratmaktadır. Yapay zekanın bu alana entegrasyonunda ise "veri gizliliği" ve "bağlam penceresi (context window) sınırı" olmak üzere iki büyük problem ortaya çıkmaktadır. Yüzlerce sayfalık hasta verisi tek bir LLM'e yüklendiğinde modelin dikkat (attention) mekanizması çökmekte ve halüsinasyonlar başlamaktadır. Ayrıca bu verilerin doğrudan üçüncü parti API'lere gönderilmesi etik ihlallere yol açmaktadır.

Literatürde, metin analizi süreçlerinde Braun ve Clarke (2006) tarafından ortaya konulan "Tematik Analiz" yöntemi altın standart olarak kabul edilmektedir. Geleneksel yapay zeka yaklaşımları bu bütüncül analizi tekil bir komutla (prompt) çözmeye çalışırken, yeni nesil araştırmalar otonom araştırma ajanlarının (Autoresearch) ve MapReduce (Parçala ve Birleştir) mimarilerinin gerekliliğine işaret etmektedir. Bu proje, Karpathy'nin "LLM OS" ve "sıfır slop (çöp veri)" felsefesinden ilham alarak, literatürdeki tekil model bağımlılığını yıkmayı ve her görevin o alanda en iyi olan ajanlara (gizlilik için yerel model, tematik çıkarım için hızlı API'ler, doğrulama için medikal teyit ajanı) asenkron olarak dağıtıldığı yenilikçi bir mimari sunmaktadır.

4. Araştırma Soruları ve Hipotez

Araştırma Soruları / Hipotez

Asenkron bir MapReduce boru hattı üzerinden yürütülen çoklu-ajan orkestrasyonu, tıbbi metinlerin analizinde tekil (monolithic) modellere kıyasla bağlam bütünlüğünü ne ölçüde korumaktadır?

1. Tıbbi teyit katmanında (Validator) RAG (Retrieval-Augmented Generation) kullanımı, nitel analiz çıktıları arasındaki medikal halüsinasyon oranlarını istatistiksel olarak ne kadar düşürmektedir?
2. Düşük donanımlı yerel sistemlerde (Ollama) koşturulan anonimleştirme ajanları, bulut API'lerine sızma (leakage) riskini tamamen ortadan kaldırabilecek bir hassasiyet düzeyine ulaşabilir mi?

Hipotez: Tıbbi nitel veri analizinde; %15 örtüşmeli "sliding window" parçalama yöntemi ve çapraz-sağlayıcı (cross-provider) doğrulama mekanizmalarından oluşan dağıtık bir sistem, manuel analize kıyasla zaman maliyetini %90 oranında düşürürken, akademik geçerlilik ve veri güvenliği kriterlerini insan uzman seviyesinde karşılayabilmektedir.

5. İş-Zaman Çizelgesi

İş Paketi / Hafta	1	2	3	4	5	6	7	8	9	10	11	12	13	14
İP-1														
İP-2														
İP-3														
İP-4														
İP-5														
İP-6														

6. Ara Rapora Kadar Gerçekleştirilen Çalışmalar

İP No	1	İP Adı	Literatür Taraması, Problem Tanımı ve Gereksinim Analizi
İP Kapsamında Gerçekleştirilenler			Tıbbi alanda nitel araştırma süreçlerinin ve mevcut yapay zeka kısıtlılıklarının literatür araştırması yapılmış, "Context Window" ve KVKK problemleri detaylıca analiz edilmiştir.

Çıktılar	Problemin netleştirilmesi ve literatür taraması dokümanı.
-----------------	---

İP No	2	İP Adı	Mimari Tasarım, Girdi-Çıktı Kontratları ve UI Mockup
İP Kapsamında Gerçekleştirilenler			Otonom analiz motorunun 5 aşamalı boru hattı (Ingestion, Privacy Guard, Map Phase, Validation, Reduce Phase) tasarlanmıştır. Her katmanın hangi LLM modeliyle (Groq, Gemini, Ollama vb.) çalışacağı ve girdi-çıktı sözleşmeleri "idea.md" şartnamesi olarak kayıt altına alınmıştır. Ön tasarım olarak Google Stitch üzerinden Streamlit tabanlı kullanıcı akışlarının (UI) prototipleri çizilmiştir. API kotalarının tüketimini önlemek adına kodlama testleri ileri bir faza planlanmıştır.
Çıktılar			Mimari şartname dokümanı (IDEA.md) ve Sistem UI Mockup'ları (Ön analiz ara çıktıları).

İP No	3	İP Adı	Temel MapReduce ve Chunking (Asenkron) Altyapısının Kodlanması
İP Kapsamında Gerçekleştirilenler			Bekletilen API anahtarları aktif edilerek LiteLLM ve asyncio kütüphaneleri üzerinden metinleri bağlam kaybı olmadan %15 örtüşme (overlap) ile 3000 tokenlik parçalara bölen asenkron motor geliştirilecektir.
Çıktılar			Eşzamanlı çalışan ve 429 Hız Sınırı hatalarına karşı dayanıklı orkestrasyon kod bloğu.

7. Ara Rapordan Sonra Yapılması Planlanan Çalışmalar

Bu bölümde dönem sonuna kadar yürütülmesi planlanan iş paketleri ayrıntılı biçimde sunulmalıdır. Her planlanan faaliyetin proje hedeflerine nasıl katkı sağlayacağı ve hangi çıktıları üreteceği açıkça belirtilmelidir. Planlamanın zaman, kaynak ve teknik uygulanabilirlik açısından tutarlı olması beklenmektedir.

İP No	4	İP Adı	Yerel PII (Gizlilik) ve Validasyon (Teyit) Ajanlarının Entegrasyonu
İP Kapsamında Gerçekleştirilecekler			İnternet erişimi kapalı yerel Ollama ajanının (Llama-3-8B vb.) tıbbi metinlerdeki PII verilerini maskeleyen entegrasyonu yapılacak ve çıkarılan temaları tıp literatürüyle karşılaştıran Validator ajanı sisteme eklenecektir.
Beklenen Çıktılar			Otonom maskeleyen modülü ve halüsinasyonları etiketleyen medikal teyit algoritması.

İP No	5	İP Adı	Sistem Testleri, Optimizasyon ve Performans Ölçümü
İP Kapsamında Gerçekleştirilecekler			Geliştirilen 5 aşamalı boru hattı (pipeline) uçtan uca çalıştırılarak test edilecektir. Belirlenen bir örneklem külliyyatı üzerinde sistem koşturulacak; yerel PII ajanının maskeleyen başarısı (Recall/Precision oranları) ve tematik kodlamanın akademik standartlarla örtüşmesi (F1-Skoru) ölçülecektir. Ayrıca çoklu ajanların eşzamanlı çalışmasından doğabilecek hız sınırı (rate limit - 429) sorunları tespit edilerek Tenacity kütüphanesi ile optimizasyonlar gerçekleştirilecektir. .
Beklenen Çıktılar			Performans doğrulama raporu, optimize edilmiş ajan kodları ve sistemin güvenilirliğini kanıtlayan metrik (Recall, Precision, F1) tabloları.

İP No	6	İP Adı	Sonuçların Değerlendirilmesi ve Final Raporlaması
İP Kapsamında Gerçekleştirilecekler			İP-5 aşamasından elde edilen nicel ve nitel performans metrikleri analiz edilerek akademik bir tartışma çerçevesinde değerlendirilecektir. Med-AgentLab (context-qualitative) altyapısının geleneksel manuel analiz yöntemlerine (MAXQDA vb.) kıyasla sunduğu zaman ve maliyet avantajları bulgularla desteklenecek, geliştirilen projenin tüm detayları "Bitirme Projesi Yazım Kılavuzu"na uygun olarak yazılacaktır.

Beklenen Çıktılar

Dönem sonu bitirme projesi tezi (final raporu), proje sunum dosyası (pitch deck/slides) ve sistemin GitHub dokümantasyonu.

Kaynaklar

Braun, V. ve Clarke, V. (2006). Using thematic analysis in psychology. *Qualitative Research in Psychology*, 3(2), 77-101.

Elo, S. ve Kyngäs, H. (2008). The qualitative content analysis process. *Journal of Advanced Nursing*, 62(1), 107-115.

Karpathy, A. (2024). *The emerging LLM OS*. (Çevrimiçi olarak yayımlanan teknik makale/görüş).

Talebirad, Y. ve Nadiri, A. (2023). Multi-agent collaboration: Harnessing the power of intelligent LLM agents. *arXiv preprint arXiv:2306.03314*, 1-15.

Thirunavukarasu, A. J., Ting, D. S. J., Elangovan, K., Gutierrez, L., Ting, T. F. ve Ting, D. S. W. (2023). Large language models in medicine. *Nature Medicine*, 29(8), 1930-1940.

Touvron, H., Martin, L., Stone, K., Albert, P., Almahairi, A., Babaei, Y. ve Scialom, T. (2023). Llama 2: Open foundation and fine-tuned chat models. *arXiv preprint arXiv:2307.09288*.

Wei, J., Wang, X., Schuurmans, D., Bosma, M., Xia, F., Chi, E. ve Le, Q. V. (2022). Chain-of-thought prompting elicits reasoning in large language models. *Advances in Neural Information Processing Systems*, 35, 24824-24837

Wu, Q., Bansal, G., Zhang, J., Wu, Y., Li, B., Zhu, E. ve Wang, H. (2023). AutoGen: Enabling next-gen LLM applications via multi-agent conversation. *arXiv preprint arXiv:2308.08155*.